

AI AGENT · ENGINEERING IN PRODUCTION

AI Agent 工程化

从 Demo 到生产 — 需要的不只是大模型

FROM DEMO TO PRODUCTION

90% 的 Agent 项目 止步于 Demo

真正进入生产，需要跨越四道工程化门槛

● 架构

● 上下文

● 评估

● 可观测

三道阻碍 Agent 落地的现实门槛

PERFORMANCE · COST · QUALITY — THREE BARRIERS BETWEEN DEMO AND PRODUCTION



PERFORMANCE

性能不稳定

多步推理累积误差

每一步 LLM 调用都有 5-10% 抖动，
叠加后总成功率断崖式下滑。

P95 延迟失控

链式调用让 P50 看似可控，
P95 / P99 翻 5-10 倍。

P95 / P50 RATIO

5-10×



COST

成本不可预测

Token 漂移 5-50 倍

同一任务，不同上下文长度、
检索条数、循环深度，价格分布极宽。

长尾任务吞掉预算

5% 的疑难任务，
常常消耗 50% 以上的 token。

COST DRIFT RANGE

5-50×



QUALITY

质量难闭环

失败原因模糊

是模型、提示词、工具，还是数据问题？
没有可观测层很难定位。

回归测试缺失

改一个 prompt，就要担心
十个老 case 是否回退。

DEBUG CYCLE COST

3-7 天

Agent 的四层骨架

PERCEPTION · REASONING · ACTION · MEMORY



L1 · PERCEPTION
感知层

输入解析

用户意图分类、槽位抽取
语言识别、敏感词过滤

多模态融合

文本 · 图像 · 表格 · 音频
统一为可推理的结构化输入

上下文窗口管理

动态截断、关键信息前置
应对长 prompt 退化



L2 · REASONING
推理层

Plan / ReAct

先拆解,再推理 → 行动
观察结果再决定下一步

Tree-of-Thought

多路径展开 · 评估剪枝
适合搜索 · 规划 · 推理任务

Reflection

自检 · 自纠 · 自我评分
配合终止条件防止无限循环



L3 · ACTION
行动层

工具调用

JSON schema 参数生成
超时 · 重试 · 鉴权治理

函数执行

沙盒 / 子进程 / WASM
代码生成必走隔离环境

API 编排

幂等 · 顺序 · 事务边界
幂等 key 防重复执行



L4 · MEMORY
记忆层

短期上下文

当前对话 / 当前任务窗口
滚动摘要防溢出

长期向量库

用户偏好 / 历史知识 / FAQ
语义 + 元数据双索引

任务级缓存

中间检索 / 工具调用结果
避免重复计算 · 降本利器

CHOOSING THE RIGHT PATTERN

Workflow · Agent · Multi-Agent — 选哪种?

三种主流模式按"路径确定性"递增 — 灵活性越高,工程化代价越大

MOST COMMON



PATTERN A

Workflow

DETERMINISTIC

- **路径固定**
DAG 编排, LLM 只填空
- **可预测**
每一步成本、延迟可量化
- **易调试**
问题定位精确到节点

适合确定性任务



PATTERN B

Agent

EXPLORATORY

- **路径动态**
运行时按情境自选下一步
- **LLM 决策**
用模型判断 → 工具/继续/终止
- **工具调用**
检索 · 计算 · 业务 API

适合半结构化探索



PATTERN C

Multi-Agent

COLLABORATIVE

- **多角色协作**
Planner · Critic · Worker
- **任务分发**
并发 / 串联 / 投票仲裁
- **上下文共享**
共享黑板 / 消息总线

适合复杂长程任务

让工具调用从“能跑”到“稳跑”

TOOL ORCHESTRATION · A SIX-STEP DISCIPLINE



上下文,才是 Agent 真正的“权重”

CONTEXT ENGINEERING · 1 CORE + 6 CAPABILITIES



上生产前,先把四张表盘装上

KPI DASHBOARD · WEEKLY ROLLUP

LIVE · W12



ACCURACY

任务成功率

92.4

%



+3.2 pp
vs. 上周

12 周累计提升 21.4 pp · 接近内部 SLO 95% 阈值



LATENCY

P95 端到端延迟

4.8

s



-18%
vs. 上周

引入并发工具调用 + 结果缓存后, P95 从 11.2s 收敛至 4.8s



COST

单次任务成本

¥0.42



-22%
vs. 上周

关键来源: 模型分级路由 + 检索结果缓存复用



RELIABILITY

30 天 SLO 达成率

99.7

%



+0.4 pp
vs. 30 日前

熔断 + 降级链路 + 多模型 fallback 兜住了三次上游事故

持续优化的真实曲线 — 准确率↑ 成本↓

UPLINE TO PRODUCTION · 12-WEEK TREND



这四类失败,你最先会遇到哪个

FAILURE MODES · FREQUENCY × DETECTION DIFFICULTY

SHALLOW · 表面易识



工具错误

VALIDATE EARLY

- **JSON schema 不匹配**
字段缺失 / 类型错位 / enum 写飞
- **参数幻觉**
不存在的参数 / 值越界 / 单位混用
- **超时无回退**



死循环

HARD STOP

- **反思链路无终止**
"我再想想" 无限循环 · 缺停机条件
- **Plan 反复修改**
每步都重新拆解 · 上下文越塞越多
- **工具调用环 · A 调 B 调 A**

DEEP · 隐蔽难定位



成本失控

METER · CAP

- **Token 漂移**
长尾 prompt 把单次成本拉爆
- **重复检索**
相同问句反复打向量库 · 无缓存
- **链路过长 · 套娃调用**



幻觉

GROUND IT

- **编造工具**
调用不存在的工具名 / API endpoint
- **编造结果**
未调真实接口就给出"数据"
- **假装成功 · "已为您发送"**

从原型到生产 — 12 周分四阶段

ROADMAP · PROTOTYPE → ENGINEERING → SCALE → PRODUCTION



SUCCESS CRITERIA 每阶段过线标准

- 01 原型 → 工程化**
金标准 case 通过率 $\geq 80\%$
- 02 工程化 → 规模化**
评估集 ≥ 100 · 自动回归绿灯
- 03 规模化 → 生产**
 $P95 < 5s$ · 单次成本 $< ¥0.5$
- 04 生产持续运营**
30 天 SLO $\geq 99.5\%$ · 成本月度下降

⚡ 不达标不晋级 — 每个阶段
必须有“通关”硬指标
否则只是“进度”假象

YOUR TURN

下一个 Agent 从工程化开始

不是"加个 LLM",是把 LLM 真正装进系统



开始 Agent 工程化



寻求合作

架构 · 上下文 · 评估 · 可观测 — 四件事一起做,才叫工程化